

从数据记录到可靠决策： 港口数据成熟度的测量与改进

摘要

港口即使拥有先进软件，也可能无法及时定位集装箱。数据与分析系统的成熟度，取决于人员、技术和治理流程能否共同支持可靠的业务交接。本文面向洲际货运公司（ICM）构建可审计的评估与改进体系，允许企业在内部计算指标，而不向外部披露保密明细。

赛题没有提供企业数值观测，因此本文严格区分可部署的评价体系与可复现的情景演示。首先，在 16 项指标字典中，通过业务覆盖约束选取 10 项高频指标，保留恢复、安全与治理检查，覆盖全部 9 类业务需求；示例采集成本由 29 单位降至 17 单位。事件编号、独立复核、缺失边界和规则版本共同保证每项分数能够追溯到证据。

建立含滞后的能力滤波模型（LCF），使用月度考核计数估计人员、技术和流程能力。经验对数几率观测方程处理样本量差异与工作负荷，行动滞后仅在状态方程中计入一次。在 48 个月的模拟实验中，测试期能力估计 RMSE 为 0.0284，低于直接月度估计的 0.0410；一步预测 RMSE 由无起效延迟模型的 0.0470 降至 0.0349。然而，名义 90% 条件区间仅覆盖 66.7% 的测试状态，因此部署前必须重新校准不确定性。

建立业务链可靠性成熟度模型（CRM），把三维能力映射为进出口业务按时、无重大数据错误交接的概率。模型采用非负能力效应、人员与流程交互及共享故障项。在 300 个独立模拟测试画像上，两条业务链的 Brier 分数分别为 0.2289 和 0.2114。期末示例画像的参考成熟度为 41.96/100，该数值不代表 ICM 真实成熟度。

建立稳健改进组合模型（RIP），同时考虑边际收益递减、实施延迟、前置依赖、人力与季度预算。穷举 16,807 种项目菜单后，选定名义投入 5.45 单位的组合；最坏规划情景净收益为 5.9671 单位，等额方案为 3.5331 单位。每单位为 1 万美元。在名义条件下，成熟度提高到 55.32/100。更宽的留出情景中仍有 5% 预算违约率，稳健保证只能解释为给定情景范围内的保证。

最后提出分阶段实施、客户报告、大小港口迁移及卡车运输企业适配方案。共享业务编号与交接指标可以帮助港口和承运商定位延误责任。客户信任应建立在可追溯记录、透明的不确定性与明确整改行动之上。

关键词：数据成熟度；状态估计；业务链可靠性；稳健优化；数据治理；不确定性

目录

1	引言：衡量业务交接的可靠性	3
2	假设、符号与信息传递	4
3	指标字典与业务覆盖筛选	5
4	数据采集协议与保密设计	6
5	数据处理：保留真实异常，避免缺失造成虚高	7
6	模型一：含滞后的能力滤波模型（LCF）	8
7	能力滤波结果与未通过的不确定性检验	9
8	模型二：业务链可靠性成熟度模型（CRM）	10
9	成熟度校准与不确定性传递	11
10	模型三：稳健改进项目组合（RIP）	12
11	优化参数与选定实施菜单	13
12	决策检验与稳健性的代价	14
13	七类情景与结构压力测试	15
14	灵敏度、可识别性与证据账本	16
15	把评分转化为人员与技术决策	17
16	治理、持续监测与分阶段实施	18
17	跨港口规模与卡车运输企业迁移	19
18	模型评价、局限与建议	20
19	致 ICM 公司客户的一封信	21
	参考文献	22
20	可复现性与 AI 使用说明	23

阅读说明。本文研究 2022 ICM D 题，全部实验均为情景模拟。用户提供的 2023 年论文仅用于参考排版。尚未提供真实队号，故保留可编辑的“未分配”标记。

1 引言：衡量业务交接的可靠性

1.1 业务问题

集装箱的实物流转与信息流转必须保持一致。到港通知、舱单、海关放行、堆场位置及内陆运输计划由不同主体产生。即使记录准确，如果在卡车离港后才到达，也可能失去业务价值。ICM 赛题因此要求评价人员、技术、流程及三者之间的联系 [1]。

本文覆盖进口与出口两条完整业务链：前者由到港信息开始，终止于内陆交接；后者由内陆接货开始，终止于装船确认。只有全部必需信息达到约定准确性并在截止时间前可用，才视为成功。成熟度不能用仪表盘、软件许可证或传感器数量替代。

1.2 任务与证据边界

1. 定义可观测 KPI 和具有业务含义的成熟度指标。
2. 把测得的能力画像转化为可实施的改进组合。
3. 制定采集、治理、检验与持续监测协议。
4. 适配不同规模港口和卡车运输企业。
5. 用一页客户信解释测量与保障机制。

ICM 仅提供业务描述，没有披露内部记录。因此，仅凭题目无法识别其真实成熟度。本文交付可部署的测量工具，并用明确标记的模拟记录检验其行为，不把模拟访谈、采购报价或财务数字写成真实证据。

1.3 方法选择依据

港口数字化需要连接多个组织，而不仅是升级设备 [2]。W3C 质量词汇区分质量维度、指标与测量值 [3]；溯源体系说明结果如何产生 [4]。这些依据支持指标字典和审计链，但不提供港口数值阈值。

静态加权评分便于计算，却无法分离观测噪声和能力变化的延迟。贝叶斯滤波提供时序分析基础 [5]。直接建模业务链概率，可以避免把相互依赖的组件可靠性机械相乘；适当评分规则用于检验概率质量 [6]；情景稳健优化再把这些概率转化为有明确边界的资源决策 [7]。

2 假设、符号与信息传递

- A1. 事件定义可比较。进出口成功必须对应有版本的截止时间与错误规则，否则跨月概率无法比较。
- A2. 能力尺度有锚点。每维由一个经核验的通过概率确定方向与尺度，演示中固定截距为零、载荷为一。
- A3. 短期响应稳定。四季度规划期内的投入响应函数保持稳定，结构变化时重新拟合。
- A4. 生成器中审核记录条件独立。实际人员、班次或船次内聚类需要单独处理，本文区间未包含这些相关性。
- A5. 损失增量不重复。避免损失对应不同进出口交易，共享事件损失只能分配一次。

表 1: 核心符号；所有概率和能力均无量纲。

符号	含义	单位
$d \in \{P, T, R\}$	人员、技术、流程	—
t, q, k, j	月、季度、业务链、项目编号	—
Y_{dt}, N_{dt}, m_{dt}	通过数、有效审核数、未知数	条
z_{dt}, a_{dt}	对数几率能力及其逆变换	—
p_k, M	业务链成功概率；成熟度	—, 0–100
x_j, s_j, G_j	项目规模、启动季度、改善上限	单位、季度、—
B_q, Z_s	季度预算；情景净收益	USD 10,000




图 1: 从证据到决策的闭环；各阶段传递区间及来源版本。

3 指标字典与业务覆盖筛选

每项指标必须回答业务问题、能够观测并支持行动。即使相关性高，恢复演练也不能被可用率替代。表2给出完整字典，星号表示高频面板入选项。C2 是结果变量，不作为额外的独立能力观测。

表 2: KPI 操作定义及管理用途。

ID	操作定义	行动或来源
P1*	岗位实操通过数/有效测试数	定向培训；考核日志
P2*	有合格人员的技能岗位数/必需岗位数	招聘、调配或外包
P3	培训后的能力保持	延后实操测试
P4	需求批准至合格人员到岗时间	招聘记录；未完成者删失
T1*	规定服务时段可用时间占比	服务与故障日志
T2*	正确交付逻辑交易数/应交付数	接口验收测试
T3	实际可用时间减要求可用时间	延迟中位数与尾部分位数
T4*	达到恢复要求的演练数/有效演练数	灾备设计与演练
R1	可用必填字段数/应填字段数	录入与结构规则
R2*	独立核验正确项/被审计项	原始凭据复核
R3	一致匹配记录数/应匹配数	共享编号对账
R4*	有有效责任人的资产数/适用资产数	责任清单
R5*	元数据达标资产数/检查数	目录与结构版本
R6*	访问与生命周期合规项/适用项	授权与处置证据
C1	工单创建至独立确认修复的时长	升级处理与根因复核
C2*	及时准确完成的业务链数/应完成数	客户交接可靠性

令 A_{gi} 表示对九类需求的覆盖：技能、配置、可靠性、互通、质量、责任与安全、元数据、生命周期和交接。对二元入选变量 z_i 求解

$$\min_z \sum_i c_i z_i \quad \text{s.t.} \quad \sum_i A_{gi} z_i \geq 1 \quad (\forall g), \quad z_i = 1 \quad (i \in \mathcal{I}_{\text{mandatory}}). \quad (1)$$

强制集合为 P2、T1、T4、R2、R4、R6、C2。枚举 2^{16} 个子集得到 10 项指标，成本 17 单位，较全量 29 单位降低 41.4%。分别提高各指标成本 20%，集合均未变化，最小 Jaccard 相似度为 1.00。这些成本是示例工时单位；低频诊断仍保留，移出高频面板不等于删除原始记录。

4 数据采集协议与保密设计

4.1 分母与分子同等重要

如果失败交易从分母中消失，成功率就没有意义。应在交付之前建立预期交易清单，为每项交接记录业务编号、发送与接收方、必需字段和截止时间。技术重试保留独立尝试编号，但共享业务编号。审核与人员记录使用假名化编号，与姓名分开存储。

最小记录包含事件编号、业务编号、业务单元、事件时间、录入时间、来源、值、质量标记和规则版本。事件时间用于归属月份，录入时间用于识别迟报。月报冻结后，补录需形成独立修订版本；来源记录缺失时，仍保留为未知结果。

4.2 分层人工核验

日志在可行时全量采集；人工测试按岗位、班次、港区、货种和负荷分层。设层总体为 N_h ，审核通过率为 y_h/n_h ，则

$$\hat{p} = \sum_h W_h \frac{y_h}{n_h}, \quad W_h = \frac{N_h}{\sum_h N_h}, \quad \widehat{\text{Var}}(\hat{p}) = \sum_h W_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{s_h^2}{n_h}.$$

(2)

设单次审核成本为 c_h ，层内标准差试估计为 S_h ，则连续最优配置满足 $n_h \propto N_h S_h / \sqrt{c_h}$ ，并要求每个相关层有最低样本量。重复人员或船次需采用聚类自助法，不能直接使用上述独立记录方差。某层无人响应时，应给出识别区间，而不能编造加权估计。

表 3: 采集风险、修正与验收依据。

风险	修正	检验
夜班响应偏低	记录分层响应；补采薄弱班次	比较样本与总体结构
明细不可离开企业	内部计算；仅输出获准汇总	在内部按凭据复现部分汇总
同一审核者设计并验证规则	冻结规则后独立复核	验证样本独立保留

演示每个维度每月使用一个同质审核层，预期测试 240 次。分层重加权是部署协议，不声称已实施企业分层调研。治理责任人批准用途、保留期限和访问权限，评估人员仅接触工作所必需的信息。

5 数据处理：保留真实异常，避免缺失造成虚高

数据分为原始层、清洗层与分析层。原始层仅追加；清洗层记录每次合并、修正和隔离原因；分析层提供计数、不确定性、适用总体与规则版本。通过溯源关系连接数据实体与处理活动 [4]。

1. **统一语义与时间**。统一时区、事件代码、资产分类及单位，调查负延迟的成因，不直接归零。
2. **按业务去重**。相同事件编号的精确重复可合并，内容冲突则隔离复核；跨系统歧义匹配保留未解决状态。
3. **区分缺失原因**。不适用、日志丢失、迟报与未完成业务分别处理。未完成招聘和工单时长属于右删失。
4. **保留真实极端值**。实际故障或异常长延误不是录入错误；稳健异常标记用于发起复核，而非自动删除。

5.1 通过率的部分识别

若应检查 N 项，已知通过 y 项，未知 m 项，则无需假设缺失机制即可得到

$$p \in \left[\frac{y}{N}, \frac{y+m}{N} \right]. \quad (3)$$

模拟第 40 月流程锚点的完整案例通过率为 45.96%，而使用全分母的有效边界为 [37.92%,55.42%]。生成器在第 40 至 41 月故意使失败记录更容易缺失。完整案例估计看似精确，却掩盖了缺失机制的不确定性。本文保留该机制下滤波器的失效表现，不以有利填补隐藏问题。

表 4: 模拟事件文件的记录守恒检查。

阶段	记录数
接收记录，含重复	35,597
合并的精确重复	1,037
唯一预期审核事件	34,560
结果已观测	33,573
保留的未知结果	987
保留的迟报标记（可重叠）	920

复现审计检查 $35,597 - 1,037 = 34,560$ 及 $33,573 + 987 = 34,560$ 。模拟文件仅标记迟报，未检验按实际接收时间预测的效果。训练、验证、测试区间依次为第 1–24、25–36、37–48 月，参数及延迟选择不使用测试结果。

6 模型一：含滞后的能力滤波模型 (LCF)

6.1 从行动到潜在能力

令每维能力 $a_{dt} = \sigma(z_{dt})$, σ 为逻辑函数。状态同时包含持续性和延迟行动输入：

$$z_{dt} = \phi_d z_{d,t-1} + (1 - \phi_d) \mu_d + \beta_d \tilde{u}_{dt} + \eta_{dt}, \quad \eta_{dt} \sim N(0, Q), \quad (4)$$

$$\tilde{u}_{dt} = \frac{\sum_{\ell=0}^2 0.6^\ell u_{d,t-\delta_d-\ell}}{1 + 0.6 + 0.6^2}, \quad u_{dt} = 0 \text{ for } t < 1. \quad (5)$$

其中 δ_d 为起效延迟，与三个月衰减窗口不同。行动效应通过状态方程积累；如果再对同一 KPI 进行滞后平滑，会重复计算延迟。观测机制为

$$Y_{dt} | z_{dt} \sim \text{Binomial}(N_{dt}, \sigma(z_{dt} - 0.25c_t)), \quad c_t = \sin(2\pi(t-1)/12). \quad (6)$$

负荷系数 -0.25 及状态扰动标准差 $\sqrt{Q} = 0.08$ 是公开的情景假设，不是 ICM 估计值。部署时需利用试点和不同负荷下的独立审核估计。

6.2 明确采用的近似方法

为便于复核，本文使用经验对数几率的高斯工作模型，而非精确二项滤波：

$$r_{dt} = \log \frac{Y_{dt} + 1/2}{N_{dt} - Y_{dt} + 1/2} + 0.25c_t, \quad (7)$$

$$R_{dt} = \frac{1}{Y_{dt} + 1/2} + \frac{1}{N_{dt} - Y_{dt} + 1/2}, \quad r_{dt} \approx z_{dt} + \epsilon_{dt}. \quad (8)$$

给定上一期滤波均值 m_{t-1} 和方差 V_{t-1} ，标量 Kalman 更新为

$$m_t^- = \phi m_{t-1} + (1 - \phi) \mu + \beta \tilde{u}_t, \quad V_t^- = \phi^2 V_{t-1} + Q, \quad (9)$$

$$K_t = V_t^- / (V_t^- + R_t), \quad m_t = m_t^- + K_t(r_t - m_t^-), \quad V_t = (1 - K_t) V_t^-. \quad (10)$$

算法 1: 估计并预测能力

输入： 月度计数、负荷与行动日期。对每个 $\delta \in \{0, 1, 2, 3\}$ ，在 1–24 月最小化高斯创新负对数似然，估计 (ϕ, μ, β) ；用 25–36 月选择延迟；冻结参数后，逐期滤波并预测 37–48 月。**输出：** $\sigma(m_t)$ 、一步预测及条件区间 $\sigma(m_t \pm 1.645\sqrt{V_t})$ 。

7 能力滤波结果与未通过的不确定性检验

本页所有数值均为情景模拟结果。




图 2: 48 个月的能力恢复；背景阴影为未参与拟合的测试区间，区间以拟合参数为条件。

表 5: 测试期误差与延迟恢复。

检验量	结果
滤波能力 RMSE / 原始月度 RMSE	0.0284 / 0.0410
含延迟一步 RMSE / 无延迟一步 RMSE	0.0349 / 0.0470
名义 90% 条件区间覆盖率	66.7%
所选延迟 (P,T,R)；生成延迟	(2, 3, 2); (2, 1, 2)

滤波降低了抽样噪声，经验证集选择的起效延迟改善了总体预测误差。然而，技术维度选择了三个月延迟，而生成真值仅一个月。短且周期性的行动序列不足以可靠识别延迟，持续性、基准水平及行动强度可能相互补偿。因此，该模型是预测工具，不能证明培训或软件改造的因果效应。

36 个测试状态中仅 24 个落入名义 90% 条件区间。失败相关缺失、参数不确定性与高斯近似均可能造成这一结果，本实验未分解各因素的贡献。实际评分前，应增加失败记录独立复核、全分母边界和通过验证集校准的预测区间；在新数据覆盖率达标之前，必须披露不确定性，不能据此作出可靠认证。

8 模型二：业务链可靠性成熟度模型 (CRM)

成熟度应回答具体问题：在约定服务环境下，数据系统有多大概率正确、及时地完成客户交接？业务链模型直接测量联合事件，不把共享平台上的各环节视为独立后机械相乘。

$$\text{logit } p_k(a, c, o) = b_{0k} + b_{Pk}a_P + b_{Tk}a_T + b_{Rk}a_R + h_k a_P a_R + \gamma_k c + \psi_k o. \quad (11)$$

人员与流程交互表示：员工技能需要结合明确责任人、一致元数据及升级路径，才能转化为业务效果。 o 表示共享系统故障，使两条业务链可以同时恶化。约束 $b_{Pk}, b_{Tk}, b_{Rk}, h_k \geq 0$ 及 $\gamma_k, \psi_k \leq 0$ ，则

$$\frac{\partial p_k}{\partial a_P} = p_k(1 - p_k)(b_{Pk} + h_k a_R) \geq 0, \quad \frac{\partial p_k}{\partial a_R} = p_k(1 - p_k)(b_{Rk} + h_k a_P) \geq 0. \quad (12)$$

上述限制避免模型在适用域内建议故意降低技能或治理水平。它们属于结构约束，不能证明现实中所有干预都有效。

8.1 区分可比能力与当前业务暴露

$$M^{\text{ref}}(a) = 100 \sum_{k=1}^2 \omega_k p_k(a, 0, 0), \quad M_t^{\text{op}} = 100 \sum_{k=1}^2 \omega_k p_k(a_t, c_t, o_t), \quad \omega = (0.6, 0.4). \quad (13)$$

参考成熟度固定负荷与故障状态；运营表现保留实际环境，必须同时报告。演示权重取自假设的进出口交易结构，而非损失严重度，货币损失权重在优化中另行使用。真实故障发生时，稳定的参考分数不能掩盖运营红色告警。

本文报告连续分数和三维能力画像。ICM 未提供有依据的等级边界，因此不编造五级成熟度。未来认证等级应同时满足经经验校准的分数阈值，以及安全、恢复、责任和生命周期条件，高平均分不能抵消关键门槛失败。NIST 的 2018 年历史框架仅用于支持风险管理结构，不用于数值换算 [8]。

算法 2: 拟合并评价业务链可靠性

输入：独立业务链结果、能力画像、负荷和故障标记。使用 1,200 个画像拟合并约束逻辑回归；用 300 个验证画像在 $\{0, 0.001, 0.01\}$ 中选择岭惩罚；冻结系数后，计算 300 个测试画像的 Brier 分数、对数损失及校准分箱。**输出：**参考与运营分数、能力画像、关键门槛状态。

9 成熟度校准与不确定性传递

本页所有数值均为情景模拟结果。试点生成器独立生成 1,800 个能力画像, 三维能力均匀分布于 $[0.2, 0.9]^3$, 负荷取自 $[-1, 1]$, 共享故障概率为 0.15; 按给定系数生成每画像两项 Bernoulli 结果。广泛画像用于提供识别交互项所需的变异, 不能把它们解释为对 1,800 个港口的实地调查。




图 3: 留出样本校准; 点面积反映分箱样本数, 虚线表示理想校准。

表 6: 独立模拟测试表现 (每条业务链 $n = 300$)。

业务链	Brier	常数基线	对数损失	真概率 RMSE
进口	0.2289	0.2506	0.6480	0.0742
出口	0.2114	0.2549	0.6117	0.0294

Brier 分数为 $n^{-1} \sum_i (p_i - y_i)^2$, 基线使用训练期成功频率。两条拟合业务链都优于基线。进口模型采用更强正则化, 系数收缩后真概率误差较大。校准分箱样本量不同, 图形属于描述性检查, 不能证明跨港口有效性。适当评分规则用于惩罚过度自信但不准确的预测 [6]。期末滤波画像为 (0.4823, 0.5384, 0.4070), 参考成熟度为 41.96。使用期末高斯状态与观测信息矩阵近似的系数分布生成 1,000 组抽样, 保留各系数向量内部协方差, 再投影到符号约束域。所得 5%–95% 分位范围为 [39.50, 52.71], 仅是近似不确定性范围, 并非已校准的 90% 置信区间; 它仍未包含状态参数不确定性、收缩偏差与跨链系数相关性。

选择接近评分 5% 和 95% 分位的两组完整联合抽样, 用于项目组合压力测试。少量代表性抽样便于求解, 但不能覆盖所有不利参数组合。

10 模型三：稳健改进项目组合 (RIP)

10.1 含延迟与边际收益递减的响应

项目 j 的投入级别 $x_j \in \{0, 1, 2, 3\}$, 启动季度 $s_j \in \{1, 2\}$ 。其在第 q 季度的响应为

$$f_{jq}^{(s)} = \min \left\{ 1, \max \left(0, \frac{q - s_j - d_j - \Delta_s + 1}{2} \right) \right\}, \quad E_{jq}^{(s)} = x_j f_{jq}^{(s)}, \quad (14)$$

$$g_j(E) = G_j^{(s)}(1 - e^{-k_j E}), \quad g_j' > 0, \quad g_j'' < 0, \quad (15)$$

$$a_q^{(s)}(x) = \text{clip} \left(a^{0,(s)} + \sum_j m_j g_j(E_{jq}^{(s)}), 0, 0.995 \right). \quad (16)$$

每季度都相对于同一个基准 a^0 计算能力增量。把累计改善量反复加到上一季度能力上, 会产生虚假增长。等价递推实现只能加入 $g_j(E_{jq}) - g_j(E_{j,q-1})$ 。

10.2 货币目标与可行性

$$Z_s(x) = \sum_{q=1}^4 \frac{\sum_k V_{kq} L_{kq}^{(s)} [p_k(a_q^{(s)}(x), 0, 0) - p_k(a^{0,(s)}, 0, 0)]}{(1+r)^{q-1}} - \sum_{q=1}^2 \frac{C_q^{(s)}(x)}{(1+r)^{q-1}}. \quad (17)$$

其中 V 是季度业务量, L 是单次交接失败损失, 二者乘积换算为万美元。安全和法定义务不与货币收益交换。令 $y_j = \mathbf{1}(x_j > 0)$, 求解

$$\max_{x,s,v} v, \quad v \leq Z_s(x) \quad (\forall s \in \mathcal{S}), \quad (18)$$

$$\sum_{j:s_j=q} \kappa_s(x_j + 0.15y_j) \leq B_q, \quad \sum_{j:s_j=q} h_j x_j \leq H_q, \quad (19)$$

$$y_{\text{integration}} \leq y_{\text{governance}}, \quad s_{\text{governance}} \leq s_{\text{integration}} \quad \text{if integration active}, \quad (20)$$

$$x_{\text{recovery}} \geq 1. \quad (21)$$

恢复投入下限是明确的情景管理决策, 不是通用标准。演示假设治理项目在启动季度即可形成初步基础, 因此允许同季度开始集成。如果现实中必须先完成验收, 应改为严格的前置依赖。人力约束代理工作量与中断影响, 本文不声称提供独立停机时长保证。

11 优化参数与选定实施菜单

本页所有数值均为情景模拟结果。

表 7: 公开的项目响应假设；成本单位为 1 万美元。

项目	G_j	k_j	d_j	h_j	$m_j = (P, T, R)$
培训	.16	.80	1	1.2	(1, 0, 0)
招聘	.18	.55	2	.7	(1, 0, 0)
系统集成	.22	.60	1	1.5	(0, 1, 0)
数据治理	.24	.75	0	1.0	(0, 0, 1)
恢复能力	.12	.65	1	.8	(0, .65, .35)

前两季度预算为 (7, 4) 单位，人力容量为 (8, 6) 单位；每个启动项目固定成本 0.15 单位，季度折现率 2%。每季度进口、出口交接量分别为 6,000 和 4,000，单次失败损失分别为 40 和 60 美元。以上全部为测试假设，并非报价或行业基准。当新增项目降低最坏净收益时，模型可以保留预算不使用。

表 8: 规划情景；另加入两组完整联合状态与系数抽样。

情景	成本	效果	额外延迟	损失价值
名义	1.00	1.00	0	1.00
超支	1.20	.90	0	1.00
延期	1.10	.80	1	1.00
低避免损失	1.05	.85	0	.80
低分/高分联合抽样	1.10	.85	0	.90

算法 3: 在明确菜单内精确搜索

输入：五项目，每项目七选项（不启动，或三个级别与两个启动时间的组合），六种情景。枚举 $7^5 = 16,807$ 种菜单，检验成本上涨 20% 时的预算、人力、依赖与恢复下限；评价所有可行菜单的情景目标，选取最小净收益最大的方案。**输出：**启动时间、投入、支出和人力，以及有限菜单内的零最优性间隙。

表 9: 选定项目菜单；未启动项目不指定时间。

项目	投入单位	启动季度	成本
培训	1	1	1.15
招聘	0	–	0.00
系统集成	0	–	0.00
数据治理	3	1	3.15
恢复能力	1	1	1.15

选定组合在第一季度支出 5.45 单位（54,500 美元），需要五个人力容量单位。成本上涨 20% 时支出 6.54 单位，低于 7 单位预算。名义期末成熟度为 55.32，提高 13.36 分。该结论仅在给定周期和响应假设下偏向治理、培训和必要恢复，招聘或集成为零不意味着应取消相应职能。

12 决策检验与稳健性的代价




图 4: 项目组合表现与预算变化后的重新优化；净收益为模拟万美元。

等额方案在第一季度向每项目投入一单位。贪心方案从恢复下限开始，反复选择名义增益最大且可行的单级增量，同样在首季启动。名义优化使用名义预算与收益，稳健优化使用全部规划情景和 20% 成本上浮边界。

表 10: 有限菜单比较，单位为万美元。

方案	名义净收益	最坏净收益	首季支出
稳健	16.3697	5.9671	5.45
名义	18.5126	4.0743	6.45
等额	14.1157	3.5331	5.75
贪心	16.5363	5.6919	5.60

12.1 留出的联合冲击

200 个留出情景中，严重度 $u \sim U(0, 1)$ 使成本变为 $1 + 0.3u$ 、效果变为 $1 - 0.3u$ ；额外延期概率 0.3，价值倍率均匀分布于 $[0.75, 1.15]$ 。一半情景以 $G \min(kE, 0.85)$ 替代指数响应。该更宽范围同时检验参数和响应结构偏差。

表 11: 更宽留出情景中的预算可靠性与可行时后悔值。

方案	平均净收益	违约率	可行时平均后悔值
等额	9.542	32.5%	2.146
贪心	11.001	19.0%	0.478
名义	9.760	69.0%	1.312
稳健	10.126	5.0%	1.253

稳健规划把违约率由 69% 降至 5%；贪心方案平均收益更高，但预算风险更大。后悔值仅将可行方案与各情景精确最优解比较，不可行情形单列；平均收益未扣除融资及应急处罚。5% 是压力测试观察值，不是机会约束保证。实际采购需要预备费或更宽的成本范围。

13 七类情景与结构压力测试




图 5: 能力与运营对比及边际收益递减；故障和旺季分数使用实际条件。

前三柱比较参考环境下的能力，后两柱是均衡画像在运营冲击下的分数，不能把五者解释为五个港口的标准化排名。

表 12: 情景问题与观察到的模型行为。

情景与检验	结果及含义
1 均衡画像 (.7, .7, .7)	参考分 65.32，作为比较基准
2 技术强、流程弱 (.7, .9, .3)	52.82，技术优势不能完全补偿治理缺口
3 培训尚未见效 (.45, .7, .7)	55.15，另以时序实验检验延迟预测
4 旺季负荷 $c = 1$	运营分 53.69，参考分仍 65.32
5 共享故障 $o = 1$	运营分 36.45，两条链同时下降
6 增加培训投入	第一单位改善.0881，第三单位.0178
7 失败相关日志缺失	第 40 月流程区间 [37.92%,55.42%]

共享故障检验说明：参考成熟度用于隔离能力差异，但运营可靠性可能立即下降。因此，客户仪表盘应先显示当前事故状态，再显示参考评分。弱治理对比也解释了为什么优化方案不会因为技术产品更易采购，就把全部资源投向技术。

这些情景是人为设计的对照，用于检验模型是否沿预期方向响应，不证明分数水平对某个具体港口真实有效。在用于合同或公开保证之前，仍需外部业务结果校准。

14 灵敏度、可识别性与证据账本

14.1 哪些变化会改变决策？

离散投入跨越预算边界时，决策可能比连续分数更敏感。预算降为原来的 80% 或 90%，稳健组合由 (1, 0, 0, 3, 1) 变为 (1, 0, 0, 2, 1)，最坏净收益降至 5.6443 单位。预算增加 10% 不改变组合；增加 20% 则增加一单位培训，最坏净收益升至 6.0447 单位。因此，增加预算的决策价值既非连续，也非恒定。

表 13: 状态扰动标准差的灵敏度；其余拟合参数固定。

变化	$\sqrt{Q}$	测试 RMSE	期末参考分
-20%	.064	.0290	42.38
0%	.080	.0284	41.96
+20%	.096	.0285	41.63

该单一参数扰动下分数变化较小，不能修复区间覆盖率不足。灵敏度与校准回答不同问题。同样，优化中的指数与分段函数比较属于结构压力测试，不是对实际响应曲率的估计。

14.2 证据账本与优先校准顺序

表 14: 来源及其能够支持的结论。

证据类别	本文使用内容	部署前所需资料
题目事实 公开文献	港口流程、保密约束、P/T/R 要求 质量与溯源概念、滤波、评分、稳健性	确认本地范围与截止要求 检查适用性与版本
情景输入	成本、人力、响应曲线、损失、生成系数	替换为报价、试点和财务记录
模拟拟合参数 管理决策	状态持续性、延迟及业务链系数 参考结构、恢复下限、风险边界	用内部历史与独立结果重估 记录责任人批准及理由

首轮试点应优先补齐失败分母和恢复证据，再收集具有变化的行动历史，以区分起效延迟与状态持续性；随后才校准采购所需的货币响应曲线。每个参数记录单位、来源字段、生效日期、方法、区间、审批人及版本。本文未实际开展专家咨询。

15 把评分转化为人员与技术决策

15.1 依据技能缺口配置人员

建立数据工程、分析、数据管家、接口运维及事故响应的岗位—技能—班次矩阵。P2 衡量必需单元的覆盖，P1 与延后的 P3 用于判断人员是否具备实操能力，而不是只看培训结业。对技能 r 、班次 h 计算

$$\text{FTEgap}_{rh} = \max \left\{ 0, \frac{\text{required task hours}_{rh} - \text{qualified available hours}_{rh}}{\text{productive hours per FTE}_h} \right\}. \tag{22}$$

考虑班次并发需求后再取整排班。长期重复缺口倾向招聘，短期专业需求倾向外包，邻近技能缺口在可安排脱产和保持能力时倾向培训。混合配置可以纳入菜单，但成本、周期、离职和知识转移责任必须记录。题目隐去人员数据，无法据此给出有依据的招聘人数。

15.2 把技术选型设计为可重复验收流程

模型不推荐具体软件品牌，而以共同业务验收测试比较候选架构：重试后逻辑消息是否正确交付、能否在批准恢复目标内恢复、身份是否互通、权限是否受控、数据是否可溯源、元数据能否导出，以及高负荷延迟。T1–T4 在服务层衡量这些结果。

表 15: 同一模型支持的架构比较。

问题	单一套件	多产品组合
集成成本	检验内部语义一致性	检验跨厂商接口与身份
共同故障	建模共享故障集中风险	建模共享网络及认证依赖
退出与迁移	检验完整导出及恢复	检验组件间数据可迁移性
经济性	许可、迁移、运维、培训	同项成本加接口维护

先在一类交接上进行受控试点，按相同负荷结构与现有服务比较，并保留回退路径。供应商宣称的准确率不能替代独立审核的 C2 成功率。只有经验证的改善和可行的资源配置，才能支持扩大部署。

16 治理、持续监测与分阶段实施

治理确定谁能定义、修改、使用和终止数据记录。每项关键数据集都应有业务责任人、技术管家、批准用途、结构定义、质量规则、保留条件和访问路径。业务责任人承担风险决策，管家执行控制，独立审核者复核证据；成熟度评分不能替代这些责任。

表 16: 监测与响应协议；阈值应来自批准的服务承诺。

频率	测量内容	责任主体	响应
每日	可用率、关键交接迟报、日志缺失、安全事件	运营与安全	事故分级、留证、通知受影响客户
每月	KPI、缺失边界、技能、工单、C2	数据责任人与人力	发布版本化报告和整改行动
每季	校准、能力漂移、项目交付	模型责任人与财务	重检模型，更新约束与预算
每年	指标范围、权限、保留、恢复	治理委员会	独立复核，必要时重新设计

事故、新数据结构、合同变化、系统迁移或校准恶化均触发额外复评，不等待年度周期。可采用连续两月校准误差超过内部批准容忍度的规则，但容忍度必须依据样本量校准，不能为减少告警随意放宽。

16.1 90 天建制，随后按季学习

- 第 1–30 天：确定范围。**盘点两条业务链、关键字段、责任人和服务承诺，建立预期事件清单及访问权限。
- 第 31–60 天：测量试点。**对照原始凭据与日志，量化未知记录，开展恢复测试，识别技能岗位缺口。
- 第 61–90 天：批准暂定决策。**发布带不确定性的连续基准分，收集报价与人员成本，选择可回退的试点组合。
- 历史数据充分后：拟合动态模型。**48 个月实验不意味着 90 天试点足以估计全部滞后；在具有足够变化的数据积累前，使用直接 KPI 与边界。

客户仪表盘显示当前事故状态、测得的交接可靠性、不确定性、记录覆盖率、未解决问题及独立复核日期。敏感人员和财务字段保留在企业内部。

17 跨港口规模与卡车运输企业迁移

17.1 含义不随规模改变，测量需本地校准

小港口不应因缺少并不需要的技术而受惩罚。保留人员—技术—流程结构、分母规则和业务链成功定义，重新校准服务时段、技能矩阵、截止时间、负荷控制及成本。小港口可采用月度抽样和简易目录，大港口可能需要连续事件流、分级责任与共享平台风险分析；两者均应证明其具备履行约定信息服务的能力。对货种、班次等分层 h ，按共同参考结构标准化：

$$p_b^{\text{std}} = \sum_h \pi_h^{\text{ref}} p_{bh}, \quad \sum_h \pi_h^{\text{ref}} = 1.$$

(23)

例如，两个能力相同的港口在常规任务上成功率 0.95，复杂任务上 0.75。90/10 结构给出 0.93，50/50 结构给出 0.85；使用共同 70/30 参考结构后，两者均为 0.89。原始八个百分点差异来自任务结构，并非能力差异。该算例用于解释标准化，不估计任何真实港口。

17.2 运输企业可兼容的成熟度指标

表 17: 从港口到卡车运输的映射。

港口要素	运输对应项	共同测试
到港与内陆计划	订单、调度、预约	编号一致且及时
堆场定位与放行	车辆位置与提货授权	位置有效且授权正确
装船确认	交付证明	闭环凭据完整可核验
港口数据岗位	调度、司机、分析师、管家	岗位实操能力

运输业务链为订单接收 → 调度 → 位置与预计到达更新 → 提货或交付 → 签收确认。必须重估响应系数与截止要求，不能照搬港口 0.6/0.4 权重或评分阈值。客户也采用兼容指标后，可以改善 ICM 到达计划、减少状态冲突、加快错误归因，并为服务复盘提供共同依据。

港口与承运商在边界共同确认业务编号和时间戳。联合成功应由匹配记录直接测量；把各自报告的成功率相乘隐含独立性，可能掩盖共享平台故障。双方保留敏感明细，仅共享获授权的异常汇总。

18 模型评价、局限与建议

18.1 框架能够完成什么

指标字典把九类业务需求连接到可检查字段与整改行动。覆盖模型在保留强制控制的同时降低示例高频采集成本。时序能力估计区分当期观测与持续状态，业务链概率再把状态转化为客户关心的服务事件。资源优化同时考虑边际收益递减和实施约束，其有限菜单最优解可独立核验。

该框架的主要价值是可追溯性：从评分可反查业务链概率、能力估计、审核计数、缺失处理及来源定义；从投资方案可追踪它在何种条件下预期改善服务。

18.2 影响实际使用的局限

1. **缺少企业验证**。全部数值参数与结果来自明确标记的模拟，不能据此给 ICM 真实评分或承诺投资回报。
2. **状态区间覆盖不足**。条件区间仅覆盖 66.7% 测试状态，不能把它们宣称为已校准的 90% 区间。
3. **部分参数不能可靠识别**。技术起效延迟恢复错误，系数收缩改变响应曲率，需要更多样化试点与独立对照观测。
4. **菜单最优性有限**。仅搜索五项目、三级投入与两个启动季度，枚举零间隙不等于对连续预算和全部可能项目全局最优。
5. **稳健性有边界**。成本超出规划范围后，更宽测试中出现 5% 违约。法律要求、灾难性损失和多年能力衰减未在演示中货币化。

18.3 建议的决策顺序

ICM 应先建立预期事件分母、失败独立复核、责任分工和恢复证据；随后公布包含缺失边界及当前事故状态的暂定能力画像。在积累具有足够变化的历史记录后，才校准业务链概率，并以本企业成本、容量和服务要求运行组合优化。

在明确声明的演示中，5.45 单位组合使名义参考成熟度从 41.96 升至 55.32。可以落实的建议是：大规模采购技术之前，先测量治理缺口和技能改善的延迟效果。数值组合始终以尚未在 ICM 验证的假设为条件。

19 致 ICM 公司客户的一封信

致: ICM 公司港口用户

发件人: 数据与分析系统评估咨询团队

主题: 让货运信息更可靠、更可追责

日期: 2026 年 9 月 19 日; 2022 年案例回顾研究

尊敬的港口用户:

您依赖准确的到港信息、海关状态、集装箱位置与提货安排开展业务。任何一条记录的延误或矛盾, 都可能影响后续运输。我们建议建立一套测量与改进机制, 使这些问题能够被发现、追踪并纠正。

该机制检查员工是否具备岗位所需技能、技术能否按时交付信息, 以及数据是否具有明确责任人和受控访问流程。同时, 它评价从首条通知到最终交接确认的完整过程。系统不会仅因采购新软件而获得较高评价。

每一项预期交接都应计入统计, 包括缺失与迟报记录。独立审核将抽取部分记录, 与原始凭据核对。报告应区分已核实结果与未知结果, 显示当前服务事故, 并说明何时修订过测量值, 使您能够理解实际表现及证据的局限。

您的信息仅用于获准用途。企业应明确访问责任、保留期限和授权共享范围。员工敏感信息与商业明细留在适当组织内部, 面向客户的报告使用获准汇总, 同时保留内部审计链。

当证据显示存在缺口时, ICM 可以根据实际预算和运营约束, 比较培训、人员配置、治理、系统集成和恢复能力等改进方案。变更应先进行有限范围试点, 明确责任并保留回退路径。我们建议每日检查当前服务状态, 每月复核表现, 每季度重新评价改进计划。

承运商可以通过共同认可的货运编号、兼容状态定义与双方确认的时间戳参与测量。这些共同指标有助于港口和客户定位交接失败发生的环节, 在无需交换多余保密记录的情况下解决差异。

本研究尚未检查 ICM 的保密系统, 文中数值例子均为模拟, 因此不能认证公司的现有成熟度, 也不能保证某个具体改善幅度。可信度应来自证据: 说明已经测量的内容, 承认仍存在的不确定性, 并持续检查整改是否有效。

我们建议 ICM 在经过独立复核的试点结束后, 发布第一份真实测得的基准报告, 并为客户提供清晰的问题反馈渠道。您反馈的不准确或迟报信息, 应纳入同一套可追踪的整改流程。

此致

数据与分析系统评估咨询团队

参考文献

- [1] COMAP. *2022 ICM Problem D: Data Paralysis? Use Our Analysis!* 2022. Problem statement supplied with this project, pp. 1–3.
- [2] I. de la Peña Zarzuelo, M. J. Freire Soeane, and B. López Bermúdez. Industry 4.0 in the port and maritime industry: A literature review. *Journal of Industrial Information Integration*, 20:100173, 2020. <https://doi.org/10.1016/j.jii.2020.100173>.
- [3] R. Albertoni and A. Isaac, eds. *Data on the Web Best Practices: Data Quality Vocabulary*. W3C Working Group Note, 15 December 2016. <https://www.w3.org/TR/vocab-dqv/>.
- [4] P. Groth and L. Moreau, eds. *PROV-Overview: An Overview of the PROV Family of Documents*. W3C Working Group Note, 30 April 2013. <https://www.w3.org/TR/prov-overview/>.
- [5] S. Särkkä. *Bayesian Filtering and Smoothing*. Cambridge University Press, 2013. <https://doi.org/10.1017/CB09781139344203>.
- [6] T. Gneiting and A. E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. <https://doi.org/10.1198/016214506000001437>.
- [7] D. Bertsimas and M. Sim. The price of robustness. *Operations Research*, 52(1):35–53, 2004. <https://doi.org/10.1287/opre.1030.0065>.
- [8] National Institute of Standards and Technology. *Framework for Improving Critical Infrastructure Cybersecurity*, Version 1.1, 2018. <https://doi.org/10.6028/NIST.CSWP.04162018>.

引用边界。文献支持概念与方法，不支持人为设定的数值测试参数。NIST 引用使用适合 2022 案例的历史版本，不声称 1.1 版是当前最新版本。公开文献于 2026 年 9 月 19 日编制时核对。

版式参考。用户提供了 2023 ICM D 题 2300229 队 25 页论文，题为 *Methods of Measuring Priority via Graph Models: Who Is the Top 1?* 本文参考其摘要页布局、编号层级、页眉及图表规范，没有将其题材、模型、数据、图形或队号作为本文内容使用。

20 可复现性与 AI 使用说明

20.1 复现实验结果

压缩包包含完整 Python 实现、模拟事件文件、试点画像、KPI 计数、结果表、矢量图和中英文 LaTeX 入口。运行 `python code/run_models.py` 即可使用 NumPy 种子 2022 重新生成实验。生成步骤位于拟合之前，使源观测和生成真值保持可区分。需要 Python、NumPy、SciPy、pandas 及 Matplotlib，实际版本记录于 `code/requirements.txt`。

状态生成器使用持续性 0.88、行动系数 0.24、基准对数几率 $(-0.65, 0.05, -0.90)$ 和起效延迟 $(2, 1, 2)$ 。行动以 12 个月为周期，每周期 4 个月启用，各维度错开。一般缺失概率 0.025，第 40–41 月的失败记录缺失概率提高至 0.20；附加 3% 重复行，迟报标记概率 0.025。业务链生成系数依次对应截距、P、T、R、 $P \times R$ 、负荷和故障：

$$\begin{pmatrix} -2.8 & 1.4 & 1.6 & 1.8 & .8 & -.5 & -1.4 \\ -3.0 & 1.7 & 1.3 & 2.0 & .6 & -.7 & -1.7 \end{pmatrix}. \quad (24)$$

以上系数仅属于数据生成器；拟合系数另存于 `results/metrics.json`。优化器使用拟合概率而非生成系数，保存结果明确标识所选项目菜单及各比较基线。

20.2 编译论文

对每个入口运行两次 XeLaTeX，或使用附带构建脚本。共用正文源文件切换中英文内容，保证公式、图形、表格及数值宏一致。包内已包含矢量图，仅编译 PDF 无需运行 Python。队号由 `preamble.tex` 中的一条命令控制。

20.3 AI 使用说明

本回顾性研究于 2026 年 9 月 19 日使用 OpenAI Codex 人工智能助手编制。用户提供建模思路、2022 年题目与 2023 年排版样例，要求分析思路、完成解题、生成中英文 PDF 并打包 LaTeX，英文版不超过 25 页。

AI 辅助涉及模型批判、文献检索、模拟与优化代码、中英文写作、LaTeX 排版及文档检查。数值结论来自实际执行的代码，并与保存结果核对。论文保留了未通过的检验结果。本文没有开展人工专家访谈、企业系统访问、外部认证或独立同行评审。本说明反映本次编制过程，计入总页数。